
上半身扰动下人形机器人摆臂行走策略的稳定性

技术报告

HumanoidVerse / Genesis / PPO

Stable Arm-Swing Humanoid Locomotion under Upper-Body Perturbations

Abstract

人形机器人在解锁上半身自由度后,行走控制不再是单纯的下肢速度跟踪问题。上肢动作会改变躯干姿态、角动量分布和足端接触节奏;若直接在基础 locomotion reward 上叠加摆臂目标,策略容易出现侧向漂移、躯干代偿、上肢抖动或摆臂信号被稳定项抑制等问题。本文面向 H1 人形机器人构建了一个三阶段强化学习奖励课程:首先在完整 19DoF 动作空间中约束上半身,学习稳定前向行走;随后借鉴 gait-conditioned reward routing 思想,根据速度命令构造站立、行走和直线行走掩码,仅在适当步态上下文中激活上肢摆臂奖励;最后在动作层对 torso、shoulder 和 elbow 注入随机脉冲扰动,使策略学习扰动后的稳定恢复。实验表明,最终策略在 32 个并行环境、20 s 评估窗口和扰动幅度 2.0 下保持 100% 存活率,前向速度误差为 0.0245 m/s,最大姿态倾斜低于 10 deg,同时保留可见肩部摆幅和手臂末端前后位移。该结果说明,稳定摆臂行走更适合被建模为一个逐步增强的 reward routing 与鲁棒性学习问题,而不是单一摆臂奖励的权重调节问题。

关键词: 人形机器人; 强化学习; 奖励设计; 摆臂; 步态条件化; 上肢扰动; 鲁棒行走

1 引言

人形机器人行走策略通常首先追求速度跟踪、姿态稳定和接触可靠性。然而,当任务从下肢行走扩展到全身协调行走时,上半身自由度会显著增加控制问题的复杂度。以 H1 机器人为例,下肢基线只控制 10 个腿部关节,而完整模型包含 19 个可控关节,包括 torso、双肩 pitch/roll/yaw 和双肘关节。直接解锁这些关节并不能自然产生人类式摆臂,因为强化学习策略会优先寻找最容易提高累计回报的行为:上肢可能保持僵硬以避免惩罚,也可能通过横向甩动、躯干扭转或高频动作获得局部 reward。

本文的核心假设是:自然摆臂不是一个独立动作,而是与当前步态、速度命令和稳定性约束耦合的协调行为。因此,摆臂奖励不应在所有状态下全局生效,而应在基础行走已




图 1: 三阶段行为证据。第一行展示上半身约束下的稳定行走；第二行展示直线行走中的可见肩部摆臂；第三行展示上肢脉冲扰动后的继续前进与恢复。

经稳定之后，根据步态上下文有条件地激活。基于这一假设，本文设计了一个从稳定下肢行走走到自然摆臂，再到上肢扰动恢复的三阶段训练流程。

本文贡献如下：

1. 在完整 19DoF H1 动作空间中构建分阶段奖励课程，避免从 10DoF 下肢策略直接迁移导致的动作维度和动力学不匹配。
2. 将 gait-conditioned reward routing 思想迁移到 H1 上肢摆臂任务中，用命令条件化掩码分离站立、行走和直线行走奖励。
3. 设计 reference-free 的上肢协调奖励，用肩部相位、左右臂速度反相和肘部末端前后幅度近似描述自然摆臂。
4. 在动作层引入上肢随机脉冲扰动，定量评估策略在 torso、shoulder 和 elbow 受扰后的存活率、速度跟踪和姿态稳定性。

2 问题建模

本文将全身行走控制表述为部分可观测马尔可夫决策过程：

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma, p_0), \quad (1)$$

其中 $s_t \in \mathcal{S}$ 表示机器人状态， $a_t \in \mathcal{A}$ 表示策略输出的关节动作， P 为转移动力学， r_t 为即时奖励， γ 为折扣因子。策略 $\pi_\theta(a_t | o_t)$ 基于本体观测 o_t 输出 19DoF 关节动作，

优化目标为：

$$J(\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right]. \quad (2)$$

动作空间可分为下肢集合 $\mathcal{L}$ 和上肢集合 $\mathcal{U}$ ：

$$\mathcal{A} = \mathcal{A}_{\mathcal{L}} \times \mathcal{A}_{\mathcal{U}}, \quad \mathcal{U} = \{\text{torso}, \text{shoulder}, \text{elbow}\}. \quad (3)$$

训练目标不是最大化某个单一摆臂指标，而是在保持 locomotion 稳定的同时，使上肢动作满足步态协调和抗扰恢复约束。因此，奖励函数被设计为分阶段逐步扩展的组合目标。

3 分阶段奖励设计

3.1 总体奖励分解

本文采用如下统一奖励形式：

$$\begin{aligned} r_t = & r_t^{\text{track}} + r_t^{\text{safe}} + m_t^{\text{stand}} r_t^{\text{stand}} + m_t^{\text{walk}} r_t^{\text{walk}} \\ & + m_t^{\text{straight}} r_t^{\text{swing}} + r_t^{\text{robust}}. \end{aligned} \quad (4)$$

其中 r_t^{track} 表示速度和朝向跟踪， r_t^{safe} 表示姿态、关节限位、动作平滑和上肢安全约束； r_t^{stand} 、 r_t^{walk} 和 r_t^{swing} 分别对应站立、行走和直线行走摆臂目标； r_t^{robust} 表示扰动阶段强化的稳定恢复目标。三个掩码 m_t^{stand} 、 m_t^{walk} 、 m_t^{straight} 使不同奖励项只在对应步态上下文中生效。

3.2 Stage I: 稳定下肢行走

第一阶段的目标是在完整 19DoF 模型中建立稳定前向行走能力。尽管动作空间包含上肢关节，训练时仍将 torso、shoulder 和 elbow 约束在默认姿态附近。该阶段对应的奖励可概括为：

$$r_t^{(1)} = r_t^{\text{track}} + r_t^{\text{base}} + r_t^{\text{foot}} - c_t^{\text{upper-lock}} - c_t^{\text{smooth}}. \quad (5)$$

其中速度与朝向跟踪项可写为：

$$r_t^{\text{track}} = w_x \exp \left(-\frac{|v_{x,t} - v_{x,t}^{\text{cmd}}|}{\sigma_x} \right) + w_\psi \exp \left(-\frac{|\psi_t - \psi_t^{\text{cmd}}|}{\sigma_\psi} \right), \quad (6)$$

而上肢锁定代价为：

$$c_t^{\text{upper-lock}} = \sum_{j \in \mathcal{U}} [|q_{j,t} - q_j^0| - \epsilon_j]_+^2. \quad (7)$$

这里 q_j^0 为默认关节角， $[\cdot]_+ = \max(\cdot, 0)$ 。该设计使策略在全身模型中学习稳定 locomotion，但不允许上肢自由度参与早期探索，从而降低优化难度并避免上肢代偿。




图 2: 分阶段 reward routing 框架。策略首先在完整 19DoF 模型中保留稳定下肢 locomotion, 随后通过命令条件化掩码激活步态相关奖励, 最后在上肢动作通道加入脉冲扰动以评估和训练恢复能力。

3.3 Stage II: 命令条件化摆臂

第二阶段在 Stage I 的基础上释放左右 shoulder pitch, 并保持 torso、shoulder roll/yaw 和 elbow 的约束。该阶段的关键不是简单增大摆臂权重, 而是将摆臂奖励路由到直线行走上下文中。命令条件化掩码定义为:

$$m_t^{\text{stand}} = \mathbf{1} \left[\|\mathbf{v}_{xy,t}^{\text{cmd}}\|_2 \leq v_{\text{stand}} \right], \quad (8)$$

$$m_t^{\text{walk}} = \mathbf{1} \left[\|\mathbf{v}_{xy,t}^{\text{cmd}}\|_2 > v_{\text{walk}} \right], \quad (9)$$

$$m_t^{\text{straight}} = \mathbf{1} \left[v_{x,t}^{\text{cmd}} > v_{\min} \wedge |v_{y,t}^{\text{cmd}}| < \epsilon_y \wedge |\omega_{z,t}^{\text{cmd}}| < \epsilon_\omega \right]. \quad (10)$$

摆臂奖励由三个主要误差项构成。首先, 肩部与对侧髋部的相位耦合为:

$$e_t^{\text{phase}} = \left(q_{L,t}^{\text{sh}} - k q_{R,t}^{\text{hip}} \right)^2 + \left(q_{R,t}^{\text{sh}} - k q_{L,t}^{\text{hip}} \right)^2. \quad (11)$$

其次, 左右肩 pitch 速度应近似反相:

$$e_t^{\text{opp}} = \left(\dot{q}_{L,t}^{\text{sh}} + \dot{q}_{R,t}^{\text{sh}} \right)^2. \quad (12)$$

最后, 左右肘部末端在机器人基坐标系中的前后位移应达到最低可见摆幅:

$$e_t^{\text{amp}} = \left[\delta_{\min} - |x_{L,t}^{\text{elbow}} - x_{R,t}^{\text{elbow}}| \right]_+^2. \quad (13)$$

因此, 第二阶段的摆臂项可写为:

$$r_t^{\text{swing}} = -w_{\text{phase}} e_t^{\text{phase}} - w_{\text{opp}} e_t^{\text{opp}} - w_{\text{amp}} e_t^{\text{amp}}, \quad (14)$$

并通过 m_t^{straight} 只在直线前进命令下激活。这一设计借鉴了 gait-conditioned reinforcement learning 中的 reward routing 思想：不同状态下的行为目标不同，奖励也应随上下文切换。

3.4 Stage III: 上肢扰动恢复

第三阶段继承第二阶段的摆臂目标，并在上肢动作通道加入随机脉冲扰动。设策略输出动作 a_t ，执行动作 $\tilde{a}_t$ 定义为：

$$\tilde{a}_{t,j} = \begin{cases} \text{clip}(a_{t,j} + s_j \eta_{t,j}, -a_{\max}, a_{\max}), & j \in \mathcal{U}, \\ a_{t,j}, & j \in \mathcal{L}, \end{cases} \quad (15)$$

其中 $\eta_{t,j} \sim \mathcal{U}(-\alpha, \alpha)$ 为随机动作偏移， s_j 为不同上肢关节的扰动缩放系数， α 为扰动幅度。扰动采用 pulse 形式：在短时间窗口中保持随机偏移，然后关闭扰动并留出恢复窗口。该机制比连续噪声更适合考察恢复能力，因为它将“受扰”和“恢复”两个阶段显式分开。

第三阶段加强了直行和姿态稳定项：

$$r_t^{\text{robust}} = w_v r_t^{v_x} + w_h r_t^{\text{heading}} - \lambda_o c_t^{\text{orientation}} - \lambda_y |v_{y,t}| - \lambda_s [v_{\min} - v_{x,t}]_+. \quad (16)$$

该阶段并不追求更大摆臂，而是要求策略在上肢被随机 action offset 扰动后仍能保持前向速度、较小侧向漂移和受控姿态倾斜。

4 与 gait-conditioned reward routing 的关系

参考论文提出的核心观点是，多 gait 或多行为学习中的主要困难来自 reward interference：站立要求静止和双脚支撑，行走要求周期性足端摆动和前向速度，跑步要求更短接触和更强 push-off。若所有 gait-specific reward 同时生效，策略会收到互相矛盾的优化信号。该论文通过 gait ID 和 reward mask 实现动态 reward routing，使共享策略在不同 gait 下优化不同目标。

本文并未完整复现该论文的多 gait ID、LSTM 策略和 centroidal angular momentum reward，而是将其思想迁移为更轻量的 command-based routing。与原论文相比，本文任务只有站立、直线行走、摆臂和扰动恢复这几个上下文；因此可以直接由速度命令构造 mask，而不必扩展观测结构。该迁移保留了 reward routing 的关键优势：摆臂项不会在站立或复杂转向中强制激活，站立稳定项也不会行走时压制必要的上肢协调。

5 实验设置

实验在 Genesis 仿真环境中训练 H1 19DoF 全身策略。评估使用 32 个并行环境，时间长度为 1000 step，即 20 s；命令速度为 $[0.6, 0, 0]$ m/s。扰动只施加于 torso、shoulder 和 elbow 动作通道，下肢动作不被直接扰动。本文报告三类指标。




图 3: 有限时长扰动评估。最终鲁棒策略在扰动幅度增大到 2.0 时仍保持完整存活率和较低速度误差；未经过扰动鲁棒训练的摆臂策略在相同扰动下出现频繁跌倒。

表 1: 上肢扰动下的有限时长评估结果。

策略	扰动幅度 α	存活率 $\uparrow$	平均存活时间 $\uparrow$	E_{v_x} $\downarrow$	平均侧向速度 $\downarrow$	最大倾斜 $\downarrow$	总跌倒次数 $\downarrow$
Stage III	0.0	100.0%	20.00 s	0.0228 m/s	0.0508 m/s	4.67 deg	0
Stage III	1.0	100.0%	20.00 s	0.0225 m/s	0.0542 m/s	7.81 deg	0
Stage III	2.0	100.0%	20.00 s	0.0245 m/s	0.0564 m/s	9.12 deg	0
Stage II baseline	2.0	0.0%	5.48 s	0.1401 m/s	0.1335 m/s	89.93 deg	95

存活率定义为：

$$S = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[T_i \geq T], \quad (17)$$

其中 T_i 为第 i 个环境第一次非 timeout reset 的时间。前向速度误差定义为：

$$E_{v_x} = \frac{1}{NT} \sum_{i=1}^N \sum_{t=1}^T |v_{x,t}^{(i)} - v_x^{\text{cmd}}|. \quad (18)$$

姿态倾斜由投影重力的水平分量近似：

$$\theta_t = \arcsin \left(\left\| \mathbf{g}_{xy,t}^{\text{proj}} \right\|_2 \right). \quad (19)$$

恢复成功率衡量每次扰动 pulse 结束后，机器人是否重新达到速度和姿态阈值：

$$\rho = \frac{1}{K} \sum_{k=1}^K \mathbf{1} [v_{x,t_k}^{\text{rec}} \geq 0.8v_x^{\text{cmd}} \wedge \theta_{t_k}^{\text{rec}} \leq \theta_{\max}]. \quad (20)$$

6 结果

结果显示，Stage III 在扰动幅度 $\alpha = 2.0$ 时仍保持 100% 存活率，前向速度误差仅从无扰动时的 0.0228 m/s 增加到 0.0245 m/s，最大倾斜保持在 9.12 deg。相比之下，Stage

表 2: 上肢摆臂相关指标。

策略	扰动幅度 α	平均上肢动作扰动	肩部摆幅	左右臂反相误差 $\downarrow$	肘部末端前后位移
Stage III	0.0	0.0000	0.2317 rad	0.4239 rad	0.1035 m
Stage III	1.0	0.1095	0.2141 rad	0.3249 rad	0.1098 m
Stage III	2.0	0.2168	0.2536 rad	0.3952 rad	0.1165 m
Stage II baseline	2.0	0.2079	0.2638 rad	0.2997 rad	0.1459 m

表 3: 探索性失败阶段的主要问题。

探索阶段	设计动机	主要问题
stage2	只释放 shoulder pitch, 引入弱相位与末端约束	摆臂信号弱, 容易被平滑、限位和回中项压制
stage3	进一步释放双臂, 强化末端和横向限制	上肢 reward 过多且方向混杂, 策略倾向僵硬或局部规避惩罚
stage4	使用固定正弦 teacher 直接塑造 shoulder pitch	teacher 与实际接触相位和速度命令不同步, 易破坏步态自然性
stage5	降低 teacher 幅度, 尝试更保守摆臂	摆臂信号进一步变弱, 仍未解决全局 reward interference

II baseline 虽然已经具有可见摆臂, 但在相同扰动下所有环境均发生失败, 平均存活时间降至 5.48 s, 并累计 95 次跌倒。表 2 进一步表明, Stage III 的鲁棒性并不是通过消除上肢运动获得的; 在 $\alpha = 2.0$ 时, 策略仍保持 0.2536 rad 的肩部摆幅和 0.1165 m 的肘部末端前后位移。

7 失败设计分析

在最终三阶段方案形成之前, 我们评估过多个探索性 reward 版本。这些版本没有稳定地产生自然摆臂, 原因主要在于 reward 目标缺少上下文路由, 或者摆臂信号与稳定性约束发生冲突。

这些失败表明, 摆臂学习不能简化为“提高某个摆臂权重”。当站立、行走、转向和扰动恢复共享同一组全局 reward 时, 策略会收到互相矛盾的梯度。有效设计需要首先保护 locomotion, 再仅在直线行走时激活 arm-leg coordination, 并在最后单独训练扰动恢复。

8 讨论

本文方法的优势在于其可解释性。每个阶段都对应明确的行为假设: Stage I 验证完整模型中的稳定下肢行走; Stage II 验证命令条件化 reward routing 能否产生可见摆臂; Stage III 验证该摆臂策略能否在上肢 action pulse 下恢复稳定。与使用 MoCap imitation 或 adversarial motion prior 的方法相比, 本文不依赖外部动作数据, 因此实现成本较低, 且 reward 项与失败模式之间的关系更容易分析。

局限性也较明确。第一，本文仍然是手工 reward shaping，摆臂自然性由 shoulder pitch 相位、速度反相和末端位移近似描述，尚未显式优化全身 centroidal angular momentum。第二，实验仍局限于仿真短时评估，不能直接声称真实机器人迁移效果。第三，当前 routing 依赖速度命令阈值；如果任务扩展到复杂转向、变速或非平地行走，可能需要更丰富的 gait state 表示。

9 结论

本文提出了一种面向 H1 人形机器人的三阶段奖励课程，使策略从稳定下肢行走逐步过渡到自然摆臂，并进一步具备抵抗上肢随机动作扰动的能力。核心结论是：上肢摆臂应被视为步态条件化的全身协调行为，而不是孤立的关节轨迹跟踪问题。通过先约束上肢建立 locomotion 基础，再使用 command-based reward routing 激活直线行走摆臂目标，最后在动作层加入上肢 pulse 扰动训练恢复能力，最终策略在强扰动下仍保持完整存活率和低速度误差，同时保留可见摆臂。该结果支持了分阶段、上下文路由和鲁棒性评估相结合的 reward 设计路线。

参考文献

- [1] T. Peng, L. Bao, and C. Zhou. Gait-conditioned reinforcement learning with multi-phase curriculum for humanoid locomotion. 2025.
- [2] N. Rudin, D. Hoeller, P. Reist, and M. Hutter. Learning to walk in minutes using massively parallel deep reinforcement learning. In *Conference on Robot Learning*, 2022.
- [3] X. B. Peng, M. Chang, G. Zhang, P. Abbeel, and S. Levine. MCP: Learning composable hierarchical control with multiplicative compositional policies. In *NeurIPS*, 2019.
- [4] X. B. Peng, Z. Ma, P. Abbeel, S. Levine, and A. Kanazawa. AMP: Adversarial motion priors for stylized physics-based character control. *ACM Transactions on Graphics*, 2021.
- [5] S. H. Collins, P. G. Adamczyk, and A. D. Kuo. Dynamic arm swinging in human walking. *Proceedings of the Royal Society B*, 2009.